


# BP神经网络


“万能的模型 + 误差修正函数”

每次根据训练得到的结果与预想的结果进行误差分析, 进而修改 **权值** 和 **阈值**, 一步步得到能输出和预想一致的模型, 此即为 BP神经网络的核心理。





神经元是以生物研究及大脑的响应机制而建立的拓扑结构网络,模拟了神经冲动的过程.



神经元拓扑结构

对于第 $i$ 个神经元,  $x_1, x_2, \dots, x_j$ 为神经元的输入, 输入常为对系统模型关键影响自变量,  $w_1, w_2, \dots, w_j$ 为连接权值调节各个输入量的占重比。由此得到神经元净

输出:

$$Net_{in} = \sum_{i=1}^n w_i * x_i$$



$\theta_i$  表示该神经元的阈值, 根据生物学中的知识, 只有当神经元接收到的信息达到阈值才会被激活.

\* 激活函数: Sigmoid 函数  $\rightarrow$  一般

当  $Net_{in} - \theta_j > 0$  时, 神经元被激活:

$$y_i = f(Net_{in} - \theta_j)$$

已知在 BP 神经网络模型中, 我们有  
三层结构: 输入层, 隐藏层, 输出层.


设:  $v_{ih}$  为输入层到隐藏层的权值

$\tau_h$  为第  $h$  个神经元的阈值 <sup>隐藏层</sup>

$w_{hj}$  为隐藏层到输出层的权值

$\theta_j$  为第  $j$  个神经元的阈值 <sup>输出层</sup>.





激活函数为 Sigmoid 函数, 则隐藏层的输出为:

$$b_h = f(\text{Netin} - r_h) = f(\alpha_h - r_h)$$

最终的输出  $y$  为:

$$y_i = f(\text{Netin} - \theta_j) = f(\beta_i - \theta_i)$$

在某个训练示例  $(x_k, y_k)$  中, 假设神经网络训练输出为

神经网络输出为

$$y_k' = (y_1^{k'}, y_2^{k'}, \dots, y_l^{k'})$$



那么这次预测结果的误差我们可以用最小二乘法表示:

$$E_k = \frac{1}{2} \sum_{j=1}^L (y_j^k - y_j^{k'})^2$$

而我们现在要做的就是调整参数一步一步缩小  $E_k$ .

参数: ①  $V_{ih}$  → 共有  $d \cdot q$  个

②  $W_{hj}$  → 共有  $q \cdot L$  个

③ 输出与隐藏神经元个数:  $q + L$

故需要调整的参数共有:

$$(d + L + 1) \times q + L$$



梯度下降法调参.

假设没有学习速率 $\eta$  ( $\eta$ 太快可能导致越过最优解,  $\eta$ 太小则会因为太慢而降低算法速率).

$$Param + = -\eta \frac{\partial E_k}{\partial Param}$$

首先我们看看隐藏层到输出层的权重调整值:

$$\Delta w_{hj} = -\eta \frac{\partial E_k}{\partial w_{hj}}$$

由此即可根据梯度下降调整参数.



现列出每一个公式:

$$\alpha_h = \sum_{i=1}^d v_{ih} x_i$$

$$\begin{bmatrix} x_1 & x_2 & x_3 & \dots & x_d \end{bmatrix} \cdot \begin{bmatrix} v_{11} & v_{12} & v_{13} & \dots & v_{1d} \\ v_{21} & v_{22} & v_{23} & \dots & v_{2d} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ v_{d1} & v_{d2} & v_{d3} & \dots & v_{dd} \end{bmatrix}$$

---

$$b_h = f(\alpha_h - \tau_h)$$

$$\beta_j = \sum_{h=1}^q w_{hj} b_h$$

$$\begin{bmatrix} b_1 & b_2 & b_3 & \dots & b_q \end{bmatrix} \cdot \begin{bmatrix} w_{11} & w_{12} & w_{13} & \dots & w_{1q} \\ w_{21} & w_{22} & w_{23} & \dots & w_{2q} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ w_{q1} & w_{q2} & w_{q3} & \dots & w_{qq} \end{bmatrix}$$

---

$$y_j^{k'} = f(\beta_j - \theta_j)$$

$$E_k = \frac{1}{2} \sum_{j=1}^l (y_j^{k'} - y_j^k)^2$$



综上所述我们可以得知  $w_{hj}$  会影响  $\beta_j$ ,  
再影响  $y_j^{k'}$ , 最后影响  $E_k$  (一个  $w$  权值  
只会影响一个  $\beta$ ) 所以我们可得:

$$\Delta w_{hj} = -\eta \frac{\partial E_k}{\partial w_{hj}} = -\eta \frac{\partial E_k}{\partial y_j^{k'}} \cdot \frac{\partial y_j^{k'}}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial w_{hj}}$$

$$\textcircled{1} \beta_j = \sum_{h=1}^a w_{hj} \cdot b_h \quad \frac{\partial \beta_j}{\partial w_{hj}} = b_h$$

$$\textcircled{2} E_k = \frac{1}{2} \sum_{j=1}^L (y_j^{k'} - y_j^k)^2 \quad \frac{\partial E_k}{\partial y_j^k} = \frac{1}{2} \cdot 2 (y_j^{k'} - y_j^k) = y_j^{k'} - y_j^k$$

$$\textcircled{3} y_j^{k'} = f(\beta_j - \theta_j) \quad \frac{\partial y_j^{k'}}{\partial \beta_j} = y_j^{k'} (1 - y_j^{k'})$$

( $f'(x) = f(x)(1 - f(x))$ )

$$\therefore \Delta w_{hj} = \eta y_j^{k'} (1 - y_j^{k'}) (y_j^k - y_j^{k'}) \cdot b_h$$